Face2Health: A Multimodal Non-Invasive Health Risk Screening Pipeline Using Vision Transformer and Monotonic Calibrated XGBoost

Phalathip Hemvut
School of Information Technology
King Mongkut's Institute of Technology Ladkrabang
Bangkok, Thailand
67070302@it.kmitl.ac.th

Eua-Unggul Chaivivatporn
School of Information Technology
King Mongkut's Institute of Technology Ladkrabang
Bangkok, Thailand
67070302@it.kmitl.ac.th

Abstract—งานวิจัยนี้นำเสนอ Face2Health ซึ่งเป็นสถาปัตยกรรมแมชชีนเลิร์นนิงแบบหลายมิติเชิงลำดับขั้น (cascading multimodal) สำหรับการคัดกรองโรคไม่ติดต่อเรื้อรังเชิงระบบ (NCDs) แบบไม่รุกล้ำร่างกาย โดยเฉพาะโรคเบาหวานชนิดที่ 2 และความดันโลหิตสูงปฐมภูมิ ไปป์ไลน์นี้ใช้ Vision Transformer (ViT-H/14) ในการทำนายค่าดัชนีมวลกาย (BMI) พร้อมการวัดความไม่แน่นอน (uncertainty quantification) ตามด้วยตัวถดถอย XGBoost แบบตารางข้อมูลสำหรับทำนายเปอร์เซ็นต์ไขมันในร่างกาย และสุดท้ายคือตัวจำแนกประเภท XGBoost ที่ผ่านการปรับเทียบด้วย Platt Scaling และควบคุมด้วยเงื่อนไขโมโนโทนิก ผู้วิจัยแสดงให้เห็นว่าเพศทางชีวภาพทำหน้าที่เป็น "ตัวดูดซับแรงกระแทกจากความผิดพลาด" (error shock absorber) โดยมีค่าสัมประสิทธิ์การลดทอน α = 0.39 และสามารถแก้ปัญหา "0-Recall Paradox" ได้ด้วยวิธีการหาจุดตัด (threshold) ที่เหมาะสมที่สุดแบบอัตโนมัติโดยไม่มีการรั่วไหลของข้อมูล (zero-leakage)

Keywords—classification, computer vision, vision transformer, MC dropout, non-invasive health screening, class imbalance, probability calibration, Platt scaling, XGBoost, monotonicity constraints, diabetes, hypertension.

I. INTRODUCTION

โรคไม่ติดต่อเรื้อรัง (NCDs) ซึ่งนำโดยโรคเบาหวานชนิดที่ 2 (T2DM) และความดันโลหิตสูงปฐมภูมิ ถือเป็นวิกฤตทางระบาดวิทยาที่สำคัญที่สุดของยุคสมัยนี้ โดยเป็นสาเหตุการเสียชีวิตมากกว่า 41 ล้านรายต่อปี คิดเป็น 74% ของการเสียชีวิตทั้งหมดทั่วโลก [1] นอกเหนือจากอัตราการเสียชีวิตแล้ว ภาวะน้ำตาลในเลือดสูงและความดันโลหิตสูงเรื้อรังที่ไม่ได้รับการตรวจพบ ยังก่อให้เกิดพยาธิสภาพของหลอดเลือดขนาดเล็กและขนาดใหญ่อย่างต่อเนื่องและไม่สามารถย้อนกลับได้ นำไปสู่โรคไตจากเบาหวาน จอประสาทตาเสื่อมแบบรุนแรง เส้นประสาทส่วนปลายเสื่อม โรคหลอดเลือดสมองตีบ และโรคหลอดเลือดหัวใจ ในประเทศรายได้ปานกลางและประเทศอุตสาหกรรมใหม่ รวมถึงประเทศไทยและภูมิภาคเอเชียตะวันออกเฉียงใต้ ภาระด้านสุขภาพนี้ยิ่งทวีความรุนแรงขึ้นจากอัตราการวินิจฉัยล่าช้าที่สูง โดยผลสำรวจสุขภาพประชากรระบุว่า 30% ถึง 45% ของผู้ป่วยเบาหวานและความดันโลหิตสูงไม่ทราบว่าตนเองป่วย จนกว่าจะเกิดภาวะแทรกซ้อนทางคลินิกที่ต้องเข้ารับการรักษาฉุกเฉิน

แนวทางการคัดกรองมาตรฐานทองคำในปัจจุบันอาศัยการเจาะเลือดดำแบบรุกล้ำ (ระดับน้ำตาลในเลือดขณะอดอาหาร ≥ 126 มก./ดล. หรือฮีโมโกลบิน A1c ≥ 6.5%) และการวัดความดันโลหิตทางคลินิก แม้วิธีการเหล่านี้จะมีความน่าเชื่อถือทางชีวเคมี แต่ก็มีข้อจำกัดเชิงโครงสร้างที่รุนแรง การเจาะเลือดดำต้องใช้วัสดุสิ้นเปลือง ปลอดเชื้อ นักเทคนิคการแพทย์ที่ได้รับการรับรอง ระบบขนส่งควบคุมอุณหภูมิสำหรับสารเคมี และโครงสร้างพื้นฐานห้องปฏิบัติการส่วนกลาง เช่นเดียวกัน การวัดความดันโลหิตที่แม่นยำต้องใช้อุปกรณ์ที่ผ่านการสอบเทียบ สภาพแวดล้อมทางคลินิกที่เงียบสงบ และบุคลากรที่ได้รับการฝึกอบรมเพื่อหลีกเลี่ยงปรากฏการณ์ "white-coat hypertension" และ "masked hypertension" ในเครือข่ายสาธารณสุขที่มีทรัพยากรจำกัด คลินิกเคลื่อนที่ในชนบท และชุมชนเกษตรกรรมห่างไกล ภาระด้านโลจิสติกส์ของการเจาะเลือดจำกัดการคัดกรองเชิงป้องกันขนาดใหญ่ให้เกิดขึ้นเพียงปีละครั้งหรือสองครั้งเท่านั้น

ในขณะเดียวกัน การศึกษาด้านมานุษยวิทยาคลินิกและสรีรวิทยาใบหน้าแสดงให้เห็นว่าภาวะไขมันสะสมเชิงระบบ กลุ่มอาการเมตาบอลิก และความแข็งตัวของหลอดเลือด ปรากฏออกมาทางกายภาพในเนื้อเยื่ออ่อนบริเวณกะโหลกศีรษะและใบหน้า การขยายตัวของเซลล์ไขมัน (adipocyte hypertrophy) ในชั้นไขมันแก้มทั้งชั้นตื้นและชั้นลึก การขยายตัวของไขมันบริเวณแก้มห้อย และความหนาของเนื้อเยื่อใต้คาง สะท้อนถึงการสะสมไขมันส่วนกลางของร่างกาย การพัฒนาของสถาปัตยกรรมดีปเลิร์นนิง โดยเฉพาะ Vision Transformers (ViT) ที่ใช้กลไก self-attention ควบคู่กับโมเดลต้นไม้ตัดสินใจแบบ gradient boosting ที่แข็งแกร่ง (XGBoost) จึงเปิดทางให้เกิดกระบวนทัศน์เชิงคำนวณที่สามารถแปลงภาพถ่ายใบหน้าดิจิทัล 2 มิติแบบพาสซีฟ ให้กลายเป็นตัวชี้วัดทางสรีรวิทยาได้ อย่างไรก็ตาม ไปป์ไลน์ที่ต่อเนื่องจากภาพสู่ข้อมูลตาราง (visual-to-tabular) ก่อให้เกิดช่องโหว่เชิงอัลกอริทึมที่สำคัญ ได้แก่ (1) การสะสมความผิดพลาดจากการถดถอยหลายขั้นตอน ซึ่งความผิดพลาดจากการประมาณค่าด้วยคอมพิวเตอร์วิทัศน์ในขั้นต้นจะแพร่กระจายไปสู่โมเดลเมตาบอลิกในขั้นถัดไป (2) ความไม่สอดคล้องเชิงชีววิทยา ซึ่งคุณลักษณะที่มีความสัมพันธ์กันสูง (เช่น BMI และเส้นรอบเอว) ทำให้ต้นไม้ตัดสินใจที่ไม่มีข้อจำกัดสร้างพื้นผิวความเสี่ยงที่ขัดกับสามัญสำนึก และ (3) ปรากฏการณ์ 0-Recall Paradox ซึ่งการปรับเทียบความน่าจะเป็นบนกลุ่มตัวอย่างที่ไม่สมดุลทำให้ความน่าจะเป็นที่ทำนายได้ต่ำกว่าจุดตัดมาตรฐานของการจำแนกประเภท ส่งผลให้ความไวทางคลินิก (sensitivity) เป็น 0% งานวิจัยนี้จึงทำการวางกรอบเปรียบเทียบประสิทธิภาพ (benchmark) และแก้ไขปัญหาเชิงระบบเหล่านี้โดยใช้ชุดข้อมูล CDC NHANES

II. LITERATURE REVIEW

A. มานุษยวิทยาสัณฐานใบหน้าและไขมันในช่องท้อง

สัณฐานวิทยาของกะโหลกศีรษะและใบหน้าทำหน้าที่เป็นตัวบ่งชี้ภายนอกของภาวะไขมันสะสมเชิงระบบ เนื่องจากการกระจายตัวที่เป็นระบบของชั้นไขมันใต้ผิวหนังและไขมันใบหน้าชั้นลึก การศึกษาเชิงสำรวจกายวิภาคโดย Coetzee และคณะ [2] พบว่าภาวะไขมันสะสมบนใบหน้าเป็นตัวชี้วัดที่น่าเชื่อถือสำหรับสุขภาพเชิงระบบ สมรรถภาพหัวใจและหลอดเลือด และภูมิคุ้มกันเยื่อเมือก Wen และ Guo [3] พิสูจน์ว่าลักษณะใบหน้าที่คำนวณได้จากคอมพิวเตอร์มีความสัมพันธ์อย่างมีนัยสำคัญกับดัชนีมวลกาย ความดันโลหิต และระดับน้ำตาลในเลือด ในเชิงกายวิภาค การสะสมไขมันทำให้เกิดการเคลื่อนตัวด้านข้างและด้านล่างบริเวณขอบขากรรไกรล่างอย่างชัดเจน เพื่อจับการเปลี่ยนแปลงเหล่านี้ จึงมีการกำหนดดัชนีเชิงเรขาคณิตที่ไม่ขึ้นกับมาตราส่วน 4 ตัว ได้แก่

- อัตราส่วนความกว้างต่อความสูงใบหน้าส่วนล่าง (LFWR): อัตราส่วนความกว้างขากรรไกรล่าง (bigonial) ต่อความสูงใบหน้าส่วนล่าง (จากใต้จมูกถึงปลายคาง) Lee และ Kim [4] แสดงให้เห็นว่า LFWR มีความสัมพันธ์อย่างมีนัยสำคัญกับพื้นที่ไขมันในช่องท้อง (VAT) ที่วัดด้วยเอกซเรย์คอมพิวเตอร์ ($r = 0.52$, $p < 0.001$)
- อัตราส่วนความกว้างแก้มต่อขากรรไกร (CJWR): อัตราส่วนความกว้างโหนกแก้มต่อความกว้างขากรรไกรล่าง การขยายตัวของไขมันแก้มที่เพิ่มขึ้นจะทำให้อัตราส่วนนี้ลดลง ซึ่งเป็นตัวชี้วัดหลักของการเกิดแก้มห้อย
- อัตราส่วนเส้นรอบรูปต่อพื้นที่ (PAR): ความกระชับเชิงเรขาคณิตของเส้นขอบขากรรไกรล่าง ค่า PAR ที่สูงบ่งบอกถึงเส้นขอบขากรรไกรที่กลมและทู่ ซึ่งสัมพันธ์กับการสะสมไขมันใต้คาง
- อัตราส่วนความกว้างต่อความสูงใบหน้า (FWHR): ความกว้างโหนกแก้มที่ทำให้เป็นมาตรฐานด้วยความสูงใบหน้าส่วนบน

ถูกใช้อย่างแพร่หลายในวรรณกรรมด้านต่อมไร้ท่อและเมตาบอลิซึม

B. การวัดความหนาแน่นมวลกระดูกด้วยรังสีเอกซ์พลังงานคู่ (DEXA) และ NHANES

แม้ดัชนีมวลกาย (BMI = น้ำหนัก/ส่วนสูง²) จะถูกใช้อย่างแพร่หลายในสาธารณสุข แต่ก็มีข้อบกพร่องพื้นฐานในฐานะตัวชี้วัดภาวะไขมันสะสมรายบุคคล เนื่องจากไม่สามารถแยกแยะระหว่างมวลกล้ามเนื้อโครงร่างและเนื้อเยื่อไขมันได้ ภาวะอ้วนร่วมกับกล้ามเนื้อลีบ (sarcopenic obesity) ซึ่งมีเปอร์เซ็นต์ไขมันสูงแต่ถูกบดบังด้วยมวลกล้ามเนื้อต่ำ ก่อให้เกิดผลการจำแนก BMI แบบผลลบปลอม การวัดความหนาแน่นมวลกระดูกด้วยรังสีเอกซ์พลังงานคู่ (DEXA) ถือเป็นมาตรฐานทองคำในการวิเคราะห์องค์ประกอบร่างกาย โดยใช้การลดทอนโฟตอนพลังงานต่ำและสูงที่แตกต่างกัน (40 keV และ 70 keV) เพื่อแยกแยะมวลแร่ธาตุกระดูก เนื้อเยื่ออ่อนปราศจากไขมัน และมวลไขมันด้วยความแม่นยำระดับต่ำกว่าเปอร์เซ็นต์

การสำรวจสุขภาพและโภชนาการแห่งชาติ (NHANES) ที่ดำเนินการโดย CDC เป็นชุดข้อมูลหลากหลายเชื้อชาติชั้นนำที่รวมการสแกน DEXA ทั่วร่างกาย (ตัวแปรเปอร์เซ็นต์ไขมันรวม DXDTOPF) การวัดสัดส่วนร่างกายมาตรฐาน (BMX) การตรวจทางชีวเคมีในห้องปฏิบัติการ (LBXGLU, LBXGH) และการสัมภาษณ์เชิงวินิจฉัยที่มีโครงสร้าง (DIQ, BPQ) [5]

C. Vision Transformers และการวัดความไม่แน่นอนเชิงความรู้ (Epistemic Uncertainty)

โครงข่ายประสาทแบบคอนโวลูชัน (CNN) ครองความโดดเด่นในการถดถอยภาพใบหน้ามาอย่างยาวนาน แต่ Dosovitskiy และคณะ [6] แสดงให้เห็นว่า Vision Transformers (ViT) มีประสิทธิภาพเหนือกว่า CNN ในงานถดถอยแบบละเอียด โดยขจัดคุณสมบัติความไม่แปรเปลี่ยนต่อการเลื่อนตำแหน่งเชิงพื้นที่ (spatial translation invariance) และหันมาใช้กลไก self-attention แบบหลายหัวทั่วทั้งภาพแทน สถาปัตยกรรม ViT-H/14 ขนาดใหญ่สามารถจำลองความสัมพันธ์เชิงพื้นที่ระยะไกลระหว่างจุดสังเกต (landmark) บนใบหน้าที่อยู่ห่างกันได้

อย่างไรก็ตาม โครงข่ายประสาทแบบกำหนดแน่นอน (deterministic) มักประสบปัญหาการทำนายผิดพลาดด้วยความมั่นใจเกินจริงเมื่อเจอข้อมูลนอกการกระจาย (out-of-distribution) เพื่อแก้ปัญหานี้ Monte Carlo Dropout (Gal & Ghahramani [7]) จึงถูกนำมาใช้เพื่อประมาณค่าแบบเบย์เซียนของกระบวนการแบบเกาส์เซียน โดยคงมาสก์ dropout ที่ทำงานอยู่ในระหว่างการอนุมาน การสุ่มทำการส่งผ่านไปข้างหน้าแบบสุ่ม (stochastic forward pass) จำนวน T=25 ครั้ง จะให้ค่าเฉลี่ยการทำนาย $\mu(x^*)$ และความแปรปรวนเชิงความรู้ (epistemic variance) $\sigma^2(x^*)$:

$$\mu(x^*) = (1/T)\ \Sigma t=1T\ fWt(x^*),\ \sigma^2(x^*) = [1/(T-1)]\ \Sigma t=1T\ [fWt(x^*) - \mu(x^*)]^2$$

หากค่า $\sigma(x^*)$ เกิน 1.80 กก./ม.² ระบบจะปฏิเสธข้อมูลนำเข้านั้นในฐานะความผิดปกติเชิงความรู้ (epistemic anomaly)

D. Gradient Boosting แบบโมโนโทนิก (XGBoost)

Extreme Gradient Boosting (XGBoost) [8] เป็นอัลกอริทึมต้นไม้ตัดสินใจแบบ gradient boosting ที่ถูกปรับให้เหมาะสมและกระจายการประมวลผล โดยลดค่าฟังก์ชันวัตถุประสงค์ที่ผ่านการขยายอนุกรมเทย์เลอร์อันดับสองพร้อมการปรับความเหมาะสม (regularization) อย่างไรก็ตาม การสร้างต้นไม้แบบโลภ (greedy) มาตรฐานมักก่อให้เกิดฟังก์ชันขั้นบันไดที่ไม่สม่ำเสมอเมื่อต้องจัดการตัวแปรที่มีความสัมพันธ์กันสูง ในทางการแพทย์คลินิก ความเสี่ยงต้องเป็นไปตามแนวโน้มทางสรีรวิทยาที่ทราบแน่ชัด (เช่น อายุ BMI หรือเส้นรอบเอวที่เพิ่มขึ้นไม่สามารถลดความเสี่ยงเบาหวานได้ในเชิงชีววิทยา) XGBoost จึงเปิดให้บังคับใช้เงื่อนไขโมโนโทนิก ($cj = +1$) ได้ดังนี้:

$$xi, j \geq xk, j \Rightarrow f(xi) \geq f(xk),\ \forall\ xl\ (l \neq j)$$

ในระหว่างการประเมินการแบ่งกิ่ง (split) โหนดที่เป็นไปได้ซึ่งละเมิดเงื่อนไข $wL^* \leq wR^*$ จะถูกตัดทิ้ง เพื่อรับประกันพื้นผิวความเสี่ยงที่เป็นโมโนโทนิกในภาพรวม

E. Platt Scaling และการปรับเทียบความน่าจะเป็น

โมเดลแมชชีนเลิร์นนิงที่ไม่ผ่านการปรับเทียบจะให้คะแนนเชิงอันดับ (ordinal) ตามอำเภอใจ ในการคัดแยกทางระบาดวิทยา คะแนนผลลัพธ์จำเป็นต้องแทนความน่าจะเป็นภายหลัง (posterior probability) ที่แท้จริง: $P(Y=1 \text{ เมื่อ } s(x) = p) = p$ Platt Scaling [9] ใช้ฟังก์ชันลอจิสติกซิกมอยด์ปรับให้เข้ากับค่า margin ของชุดตรวจสอบ (validation) z:

$$P(Y = 1; z) = 1 / [1 + \exp(A \cdot z + B)]$$

พารามิเตอร์ A และ B ถูกประมาณค่าผ่านวิธี maximum likelihood แบบ cross-entropy แม้ Platt scaling จะลดค่า Brier score ได้ แต่ก็ทำให้ความน่าจะเป็นที่ทำนายได้ยึดติดกับความชุกเชิงประจักษ์ (empirical prevalence) ของกลุ่มข้อมูลฝึกฝน (ประมาณ 10% สำหรับเบาหวาน) ก่อให้เกิดความล้มเหลวในการจำแนกประเภทแบบไม่สมดุลอย่างรุนแรงภายใต้จุดตัดมาตรฐานเริ่มต้น [10]

F. ทฤษฎีการตัดสินใจและการหาจุดตัดที่เหมาะสมที่สุด

ในการคัดกรองโรคทางคลินิก ต้นทุนความผิดพลาดของการจำแนกประเภทมีความไม่สมมาตรสูง ต้นทุนทางเศรษฐศาสตร์สุขภาพของผลลบปลอม (False Negative, CFN > 10,000 ดอลลาร์สหรัฐฯ ในการล้างไตฉุกเฉินหรือการรักษาโรคหลอดเลือดสมอง) สูงกว่าต้นทุนของผลบวกปลอม (False Positive, CFP ≈ 15 ดอลลาร์สหรัฐฯ สำหรับการตรวจเลือดจากปลายนิ้ว) อย่างมหาศาล ทฤษฎีการตัดสินใจระบุว่าจุดตัดการจำแนกประเภทที่เหมาะสมที่สุด τ^* ควรมีค่า $\tau^* \ll 0.50$ [11] งานวิจัยนี้ประเมินเกณฑ์การหาค่าที่เหมาะสมที่สุดอย่างเป็นทางการ 2 แบบ:

Fig. 1. สถิติ Youden's J: $J(\tau) = \text{ความไว}(\tau) + \text{ความจำเพาะ}(\tau) - 1 = TPR(\tau) - FPR(\tau)$

Fig. 2. ค่าวัด Fβ (β=2): $F2(\tau) = (5 \times TP) / (5 \times TP + 4 \times FN + FP)$ ซึ่งให้น้ำหนักกับค่า Recall มากกว่า Precision ถึงสองเท่า

G. ความแตกต่างจากงานวิจัยก่อนหน้าด้านการประเมินสุขภาพจากใบหน้า

งานวิจัยก่อนหน้าเกี่ยวกับการประเมินสุขภาพจากใบหน้ามักใช้ CNN แบบ end-to-end ที่เป็นกล่องดำ ซึ่งทำการแมปพิกเซลใบหน้าไปสู่ป้ายกำกับโรคแบบทวิภาคโดยตรง แนวทางแบบองค์รวมเช่นนี้ล้มเหลวในการนำไปใช้จริงทางคลินิกด้วยเหตุผลสามประการ ได้แก่ (1) ไม่มีการประมาณความไม่แน่นอนเลย เสี่ยงต่อการทำนายผิดพลาดแบบเงียบในฟีโนไทป์ใบหน้าที่ไม่ได้มาตรฐาน (2) ไม่สามารถนำตัวแปรร่วมทางคลินิกที่สำคัญ (อายุ เพศทางชีวภาพ กิจกรรมทางกาย) มาใช้ได้ และ (3) ขาดความโปร่งใสโดยสิ้นเชิงในการแพร่กระจายความผิดพลาด ในทางตรงกันข้าม Face2Health นำเสนอสถาปัตยกรรมแบบแยกส่วน (modular) ที่ตัวชี้วัดทางชีวภาพระหว่างทาง (BMI สัดส่วนใบหน้า เปอร์เซ็นต์ไขมันในร่างกาย) ถูกวัดค่า ปรับเทียบ และควบคุมด้วยเงื่อนไขโมโนโทนิกเชิงชีววิทยาอย่างชัดเจน

III. METHODOLOGY

A. ภาพรวมกระบวนการและสถาปัตยกรรมแบบลำดับขั้น

กรอบการทำงาน Face2Health ดำเนินการผ่าน 3 ขั้นตอนต่อเนื่องแบบแยกส่วน:

[1] ขั้นที่ 1 (คอมพิวเตอร์วิทัศน์และมานุษยวิทยาสัณฐาน): ภาพถ่ายใบหน้าตรงจะถูกประมวลผลเบื้องต้นผ่าน MediaPipe Face Mesh หากตำแหน่งใบหน้าเอียงเกิน ±15 องศาในแนวก้ม เงย หรือหมุน โมดูล Face Guard จะปฏิเสธเฟรมภาพนั้น ใบหน้าที่ผ่านการตรวจสอบแล้วจะถูกทำให้เป็นมาตรฐาน (518x518x3) และประมวลผลโดย ViT-H/14 เทคนิค MC Dropout (25 รอบ) จะให้ค่า BMI โดยประมาณ μ และความไม่แน่นอนเชิงความรู้ σ ในขณะเดียวกัน พิกัดจุดสังเกต 468 จุดจะให้ค่าอัตราส่วน LFWR, CJWR, PAR และ FWHR

[2] ขั้นที่ 1.5 (การถดถอยข้อมูลตาราง DEXA): ค่า BMI โดยประมาณ อายุ เพศทางชีวภาพ (ชาย=1, หญิง=0) และระดับกิจกรรมทางกาย จะถูกส่งต่อไปยังตัวถดถอย XGBoost ที่ฝึกฝนบนข้อมูลสแกน DEXA ของ NHANES เพศทางชีวภาพทำหน้าที่เป็นตัวดูดซับความแปรปรวน

[3] ขั้นที่ 2 (การจำแนกความเสี่ยงแบบโมโนโทนิกที่ปรับเทียบแล้ว): คุณลักษณะข้อมูลตาราง [อายุ, เพศ, BMI ที่ทำนาย, เปอร์เซ็นต์ไขมันที่ทำนาย, (เส้นรอบเอว)] จะถูกประเมินโดยตัวจำแนก XGBoost ที่ควบคุมด้วยเงื่อนไขโมโนโทนิกและปรับเทียบผ่าน Platt scaling แบบภายใน 5-fold ความน่าจะเป็นที่ปรับเทียบแล้วจะถูกนำไปคัดแยกโดยใช้จุดตัดที่ผ่านการปรับให้เหมาะสมด้วยชุดข้อมูลตรวจสอบ

B. ขั้นตอนการแบ่งข้อมูล 3 ทางแบบปราศจากการรั่วไหล (Zero-Leakage)

เพื่อรับประกันความสามารถในการทำซ้ำเชิงวิชาการอย่างเคร่งครัดและขจัดการรั่วไหลของข้อมูล กลุ่มตัวอย่าง NHANES ที่คัดสรรแล้วถูกแบ่งออกเป็นชุดฝึกฝนแบบแบ่งชั้น (70%) ชุดตรวจสอบ (15%) และชุดทดสอบที่กันไว้ล่วงหน้า (15%) โมเดลปรับเทียบและตัวประมาณค่าฐาน XGBoost ได้รับการฝึกฝนจากชุดข้อมูล 70% เท่านั้น การหาจุดตัดที่เหมาะสมที่สุด (τ^*) ดำเนินการบนชุดตรวจสอบ 15% เท่านั้น ส่วนตัวชี้วัดการประเมินผลสุดท้ายคำนวณจากชุดทดสอบที่กันไว้ล่วงหน้า ซึ่งไม่เคยถูกเปิดเผยเลยในระหว่างการฝึกฝนและปรับแต่ง

C. การพิสูจน์ทางคณิตศาสตร์ของตัวดูดซับแรงกระแทกจากความผิดพลาดด้านเพศ

ให้เปอร์เซ็นต์ไขมันในร่างกายที่ทำนาย θ เป็นฟังก์ชันของ BMI โดยประมาณ b, อายุ a, เพศ s, และเส้นรอบเอว w: $\theta = f(b, a, s, w)$ ความผิดพลาดต้นทางในค่า BMI คือ $\delta b = b - b^*$ จากการขยายอนุกรมเทย์เลอร์อันดับหนึ่ง:

$$\delta\theta \approx |\partial f / \partial b| \cdot \delta b = \alpha \cdot \delta b$$

หากค่า $\alpha < 1.0$ ขั้นที่ 1.5 จะลดทอนความผิดพลาดจากคอมพิวเตอร์วิทัศน์ในขั้นต้นทาง ดังที่พิสูจน์เชิงประจักษ์ในส่วนที่ IV เพศทางชีวภาพคิดเป็น 74.99% ของการตัดสินใจแบ่งกิ่งในต้นไม้ ให้ค่า $\alpha = 0.39$ เมื่อมีเส้นรอบเอว และ $\alpha = 1.00$ เมื่อไม่มีเส้นรอบเอว ดังนั้น ขั้นที่ 1.5 จึงทำหน้าที่เป็นตัวดูดซับแรงกระแทกจากความแปรปรวนอย่างชัดเจน

IV. EXPERIMENTAL RESULTS AND DISCUSSION

A. การวิเคราะห์เชิงลึกเชิงประจักษ์ของปรากฏการณ์ 0-Recall Paradox

การประเมินตัวจำแนกเบาหวานพื้นฐานในขั้นที่ 2 บนชุดทดสอบที่กันไว้ (N=531) เผยให้เห็นการกระจายตัวของความน่าจะเป็นที่ทำนายได้เชิงประจักษ์ซึ่งอยู่ในช่วง $\mu = 0.1022$ และ $\max(p) = 0.3776$ เนื่องจากไม่มีผู้ใดเลยที่ข้ามจุดตัดมาตรฐานเริ่มต้น 0.50 โมเดลพื้นฐานจึงแสดงความล้มเหลวในการคัดกรองอย่างสมบูรณ์ คือ 0 ผลบวกจากการทำนาย จากทั้งหมด 531 ราย ให้ค่าความไว (sensitivity) 0.00% (55/55 เป็นผลลบปลอม) ดังแสดงในตารางที่ II-A และ II-B การเปลี่ยนจากจุดตัดมาตรฐานเริ่มต้น (τ=0.50) ไปเป็นจุดตัด Youden's J พื้นฐาน (τ=0.082) สามารถตรวจจับผู้ป่วยได้ 43 ราย (ความไว 78.18%, ผลลบปลอม 12 ราย) ที่สำคัญคือ การนำโมเดล XGBoost ที่ปรับเทียบแล้วและควบคุมด้วยเงื่อนไขโมโนโทนิกมาใช้ภายใต้จุดตัดคัดกรอง F2 ที่ผ่านการปรับให้เหมาะสม (τ^*=0.061) สามารถบรรลุความไวถึง 89.09% (ผลบวกจริง 49 ราย เหลือผลลบปลอมเพียง 6 ราย) ช่วยชีวิต 49 คนที่มิฉะนั้นจะได้รับการรับรองสุขภาพที่ผิดพลาดและอันตราย สำหรับงานคัดกรองหลักที่ไม่ใช้ค่าเส้นรอบเอว จุดตัดคัดกรอง F2 (τ^*=0.060) บรรลุความไว 90.91% (ตรวจพบผู้ป่วย 50 จาก 55 ราย, ช่วยชีวิตเพิ่ม 50 ราย) ในทำนองเดียวกัน สำหรับการคัดกรองความดันโลหิตสูง จุดตัดคัดกรอง F2 ที่ผ่านการปรับให้เหมาะสม (τ^*=0.158) ทำให้ความไวเพิ่มขึ้นจาก 49.72% (ผลลบปลอม 91 ราย) เป็น 88.40% (ผลลบปลอม 21 ราย) ช่วยชีวิตผู้ป่วยความดันโลหิตสูงได้ 70 ราย

B. พลวัตเชิงปริมาณของการแพร่กระจายความผิดพลาด

เพื่อยืนยันว่าความผิดพลาดจากการประมาณค่าของ ViT ในขั้นต้นทางไม่ทำให้การทำนายในขั้นปลายทางไม่เสถียร จึงมีการทดสอบด้วยการรบกวนค่าอย่างเป็นระบบ (ΔBMI $\in$ [-3, +3] กก./ม.^{2}) บนชุดข้อมูลทดสอบทั้งหมด ตารางที่ III พิสูจน์ว่าเมื่อมีค่าเส้นรอบเอวอยู่ด้วย ตัวถดถอยจะมีค่าสัมประสิทธิ์การลดทอน $\alpha = 0.39$ การประมาณค่าเกินจริง 2.0 กก./ม.^{2} แปลงเป็นการเปลี่ยนแปลงสัมบูรณ์ในเปอร์เซ็นต์ไขมันรวมเพียง 0.77% เท่านั้น

C. เศรษฐศาสตร์สุขภาพทางคลินิกและชั้นการคัดแยก

ภายใต้จุดตัดคัดกรอง F2 ที่ผ่านการปรับให้เหมาะสม ($\tau^* = 0.061$) ค่าความแม่นยำ (precision) ของเบาหวานอยู่ที่ 16.78% ในเชิงเศรษฐศาสตร์การคัดกรองทางคลินิก นี่ถือเป็นการแลกเปลี่ยนที่ยอดเยี่ยม กล่าวคือ ทุก ๆ 6 รายที่ถูกคัดแยกเป็นผลบวก จะมี 1 รายที่ยืนยันว่าเป็นเบาหวานจริง และอีก 5 รายจะได้รับการตรวจเลือดยืนยันเพิ่มเติมที่มีราคาไม่แพง ไม่รุกล้ำ (15 ดอลลาร์สหรัฐฯ) การช่วยชีวิตผู้ป่วยเบาหวาน 49 รายจากการวินิจฉัยที่ล่าช้า ช่วยป้องกันภาวะแทรกซ้อนระยะยาวที่มีมูลค่าเกิน 10,000 ดอลลาร์สหรัฐฯ ต่อผู้ป่วยต่อปี ความน่าจะเป็นที่ปรับเทียบแล้วถูกนำมาจัดดำเนินการเป็น 4 ชั้นการคัดแยกทางคลินิก

ตารางที่ I. การแบ่งกลุ่มตัวอย่าง NHANES แบบแบ่งชั้น (N=3,540 เบาหวาน, N=3,554 ความดันโลหิตสูง)

Target Condition	Cohort Partition	Total (N)	Positive Cases	Base Prevalence
Diabetes (DIQ010)	Train (70%)	2,477	256	10.33%
Diabetes (DIQ010)	Validation (15%)	532	55	10.34%
Diabetes (DIQ010)	Held-Out Test (15%)	531	55	10.36%
Hypertension (BPQ020)	Train (70%)	2,488	845	33.96%
Hypertension (BPQ020)	Validation (15%)	533	181	33.96%
Hypertension (BPQ020)	Held-Out Test (15%)	533	181	33.96%

ตารางที่ II-A. การเปรียบเทียบประสิทธิภาพโรคเบาหวาน (N=531)

Route	Model	Cutoff (τ^*)	AUC	Sens(%)	Spec(%)	Rescued
With Waist	Base (Default)	0.500	0.747	0.0%	100.0%	0
With Waist	Base (Youden)	0.082	0.747	78.2%	58.8%	+43
With Waist	Opt (F2)	0.061	**0.763**	**89.1%**	49.0%	**+49**
No Waist	Base (Default)	0.500	0.747	0.0%	100.0%	0
No Waist	Opt (F2)	0.060	**0.762**	**90.9%**	48.7%	**+50**

ตารางที่ II-B. การเปรียบเทียบประสิทธิภาพความดันโลหิตสูงปฐมภูมิ (N=533)

Route	Model	Cutoff (τ^*)	AUC	Sens(%)	Spec(%)	Rescued
With Waist	Base (Default)	0.500	0.760	49.7%	82.4%	0
With Waist	Opt (F2)	0.158	0.755	**88.4%**	41.8%	**+70**
No Waist	Base (Default)	0.500	0.761	50.3%	82.7%	0
No Waist	Opt (F2)	0.155	0.757	**90.6%**	40.9%	**+73**

ตารางที่ III. การลดทอนเปอร์เซ็นต์ไขมันภายใต้การรบกวนค่า BMI

Injected ΔBMI (kg/m^2)	Mean ΔBF With Waist	Attenuation (α)	Mean ΔBF No Waist
-2.0	-0.80 ± 0.80%	0.40	-2.02 ± 1.24%
-1.0	-0.37 ± 0.50%	0.37	-1.01 ± 0.82%
0.0	0.00 ± 0.00%	—	0.00 ± 0.00%
+1.0	+0.39 ± 0.54%	**0.39**	+1.00 ± 0.83%
+2.0	+0.77 ± 0.72%	0.38	+1.98 ± 1.14%

V. CLINICAL LIMITATIONS & BOUNDARIES

Face2Health เป็นเพียงเครื่องมือคัดแยกเชิงโอกาส (opportunistic triage) เท่านั้น ไม่ใช่เครื่องมือวินิจฉัยโรค และไม่สามารถใช้ทดแทนการเจาะเลือดทางชีวเคมีอย่างเป็นทางการหรือการวัดความดันโลหิตทางคลินิกได้ ขอบเขตของประสิทธิภาพประกอบด้วย (1) ความไวต่อสภาพแสงที่รุนแรงเกินไปและท่าทางศีรษะที่เอียงเกิน ±15 องศา (ซึ่งถูกดักจับโดย Face Guard) (2) การเปลี่ยนแปลงของโดเมนข้อมูลที่อาจเกิดขึ้นในกลุ่มสีผิวตามมาตรา Fitzpatrick ประเภท I–VI ซึ่งต้องมีการปรับเทียบใหม่ในระดับท้องถิ่น และ (3) ข้อห้ามทางคลินิกในการสั่งจ่ายยาโดยตรงโดยไม่มีการตรวจยืนยันทางคลินิกเพิ่มเติม

VI. CONCLUSION & FUTURE WORK

งานวิจัยนี้พัฒนาและทดสอบความถูกต้องของ Face2Health โดยแสดงให้เห็นว่าคอมพิวเตอร์วิทัศน์แบบพาสซีฟสามารถถูกผนวกเข้าเป็นเครื่องมือคัดแยกแบบไม่รุกล้ำที่ผ่านการปรับเทียบเชิงระบาดวิทยาได้ ด้วยการระบุและแก้ไขปัญหา 0-Recall Paradox ผ่านการค้นหาจุดตัดแบบปราศจากการรั่วไหลของข้อมูลจากชุดตรวจสอบ ความไวในการคัดกรองบรรลุ 89.09% สำหรับเบาหวาน และ 88.40% สำหรับความดันโลหิตสูง บนข้อมูล NHANES ที่กันไว้ล่วงหน้า นอกจากนี้ ยังพิสูจน์ได้ว่าเพศทางชีวภาพทำหน้าที่เป็นตัวดูดซับแรงกระแทกจากความผิดพลาด ($\alpha = 0.39$) ซึ่งช่วยป้องกันตัวจำแนกในขั้นปลายทางจากสัญญาณรบกวนของการถดถอยเชิงภาพ เมื่อผนวกกับเงื่อนไขโมโนโทนิกแล้ว ไปป์ไลน์นี้จึงวางรากฐานทางคณิตศาสตร์ที่มั่นคงสำหรับการคัดกรองสุขภาพประชากรอย่างเท่าเทียม

ทิศทางในอนาคตมุ่งเน้นไปที่ (1) การทดสอบความถูกต้องทางคลินิกเชิงคาดการณ์ล่วงหน้าแบบหลายศูนย์ในคลินิกผู้ป่วยนอกของภูมิภาคเอเชียตะวันออกเฉียงใต้ (2) การผนวกเทคนิค remote photoplethysmography (rPPG) สำหรับการประมาณค่าความเร็วคลื่นชีพจรเชิงแสง และ (3) การนำโมเดล ONNX ขนาดเบามาใช้งานสำหรับการคัดกรองแบบออฟไลน์บนสมาร์ตโฟน

REFERENCES

[1] World Health Organization, "Global report on hypertension: the race against a silent killer," World Health Organization, Geneva, Switzerland, Tech. Rep., 2023.

[2] V. Coetzee, D. I. Perrett, and I. D. Stephen, "Facial adiposity: A reliable cue to health?" Perception, vol. 38, no. 11, pp. 1700–1711, 2009.

[3] F. Wen, Z. Guo, and Y. Xu, "Computation of facial adiposity and its relationship to metabolic health," IEEE Trans. Biomed. Eng., vol. 60, no. 8, pp. 2145–2152, 2013.

[4] B. J. Lee and J. Y. Kim, "Predicting visceral obesity based on facial characteristics," BMC Complement. Altern. Med., vol. 14, no. 1, pp. 1–9, 2014.

[5] Centers for Disease Control and Prevention (CDC), "National Health and Nutrition Examination Survey (NHANES) Examination & Laboratory Protocols," U.S. Dept. of Health & Human Services, 2020.

[6] A. Dosovitskiy et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in Proc. Int. Conf. Learn. Represent. (ICLR), 2021.

[7] Y. Gal and Z. Ghahramani, "Dropout as a bayesian approximation: Representing model uncertainty in deep

learning," in Proc. Int. Conf. Mach. Learn. (ICML), pp. 1050–1059, 2016.
[8] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min., pp. 785–794, 2016.
[9] J. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," Adv. Large Margin Classif., vol. 10, no. 3, pp. 61 74, 1999.
[10] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in Proc. 22nd Int. Conf. Mach. Learn. (ICML), pp. 625–632, 2005.
[11] W. J. Youden, "Index for rating diagnostic tests," Cancer, vol. 3, no. 1, pp. 32–35, 1950.
[12] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, 2nd ed. Sebastopol, CA: O'Reilly Media, 2019.
[13] Z.-H. Zhou, Ensemble Methods: Foundations and Algorithms. Boca Raton, FL: CRC Press, 2012.
[14] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), pp. 770–778, 2016.
[15] J. Bergstra and Y. Bengio, "Random search for hyper-parameter optimization," J. Mach. Learn. Res., vol. 13, pp. 281–305, 2012.